

Age Estimation



Marie Chaneac
Alpha Ba
Ines Barkan

Deep learning for age prediction from facial images

APPA-REAL dataset

- Dataset APPA-REAL : 7 591 images de visages avec âge réel et âge apparent, âges de 0 à 95 ans.
- 54% train, 20% validation, 26% test.

Modèle de base pour l'estimation de l'âge



- Best val mae : 4.159
- Test mae : 5.191

Le Modèle se trompe de 5 ans environ.

```
> start testing
100%|█| 25/25 [00:30<00:00, 1.21s/it, stage=val, epoch=0, loss=0.0393, mae=5.19
test loss: 0.039
test mae: 5.191
test acc: 0.088
=> MAE by age group:
  0-17 yrs: mae=3.418, n=311, std(err)=6.494
  18-45 yrs: mae=4.587, n=1241, std(err)=4.328
  46-100 yrs: mae=8.244, n=426, std(err)=8.041
```


Dex Method vs Residual Dex Method

DEX Method

— Deep EXpectation —

Classify Ages

Predict age as a probability distribution.



$$\hat{y} = \sum p_i \cdot i$$

p_i : probability for age i

K : max age

- ✓ Stable Training
- ✓ Captures Uncertainty

Rothe et al., IJCV 2016

Residual DEX Method

— + Residual Correction —

Refine Predicted Age



$$\hat{y} = Age + r(x)$$

Age: DEX estimate


$r(x)$: regression correction

- ✓ More Precise
- ✓ Reduces MAE

Agustsson et al., FG 2017


Dex Method vs Residual Dex Method

Test Mae : 4.762
Best Val Mae : 3.924





```
test mae: 4.762
test acc: 0.096
=> MAE by age group:
  0-17 yrs: mae=4.091, n=311, std(err)=5.800
  18-45 yrs: mae=3.817, n=1241, std(err)=3.219
  46-100 yrs: mae=8.004, n=426, std(err)=7.070
```

Test Mae : 4.730
Best Val Mae : 3.816





```
test mae: 4.730
test acc: 0.096
=> MAE by age group:
  0-17 yrs: mae=3.731, n=311, std(err)=5.853
  18-45 yrs: mae=3.935, n=1241, std(err)=3.404
  46-100 yrs: mae=7.775, n=426, std(err)=6.689
```

Dex Method vs Residual Dex Method



Residual Dex Method with MSE as loss function



Modélisation de l'incertitude

- L'estimation d'âge à partir d'images est incertaine (variabilité humaine, qualité image).

Approches comparées :

- **Gaussian loss** → réseau prédit moyenne + variance
- **Laplacian loss** → réseau prédit moyenne + échelle

Gaussian Negative Log-Likelihood

On suppose que l'âge réel suit une loi normale/gaussienne autour des prédictions du modèle


$y \mid x \sim \mathcal{N}(\mu(x), \sigma^2(x))$ avec $\mu(x) = \hat{y}$ la prédiction de l'âge sachant l'image x

Alors la loss est calculée avec la formule


$$\mathcal{L}(x, y) = \frac{(y - \mu(x))^2}{2\sigma^2(x)} + \frac{1}{2} \log(\sigma^2(x))$$

Forte pénalisation des grandes erreurs $\rightarrow$ modèle sensible aux valeurs aberrantes

Gaussian Negative Log-Likelihood



```
=> [epoch 028] best val mae was improved from 4.400 to 4.398
100% 66/66 [01:05<00:00, 1.01it/s, stage=train, epoch=29, loss=0.0727, mae=4.5837]
100% 12/12 [00:07<00:00, 1.51it/s, stage=val, epoch=29, loss=0.0359, mae=4.3587]
=> [epoch 029] best val mae was improved from 4.398 to 4.359
=> training finished
additional opts: []
best val mae: 4.359
```



```
=> creating model 'se_resnext50_32x4d'
=> loading checkpoint 'checkpoint/epoch029_0.03594_4.3587.pth'
=> loaded checkpoint 'checkpoint/epoch029_0.03594_4.3587.pth'
=> start testing
100% 16/16 [00:22<00:00, 1.41s/it, stage=val, epoch=0, loss=0.0384, mae=4.9916]
test loss: 0.038
test mae: 4.992
```

Convergence lente

Laplace Negative Log-Likelihood

On suppose cette fois que l'âge réel suit une distribution de Laplace autour des prédictions du modèle


$$y \mid x \sim \text{Laplace}(\mu(x), b(x))$$

La fonction de loss utilisée par le modèle est

$$\mathcal{L}(x, y) = -\log p(y \mid x) = \frac{|y - \mu(x)|}{b(x)} + \log(2b(x))$$

Erreur absolue au lieu de quadratique → modèle moins sensibles aux valeurs aberrantes

Laplace Negative Log-Likelihood




Le modèle converge rapidement et avec des courbes train/validation proches, indiquant une bonne généralisation et peu d'overfitting.

Méthode Ordinal (ou Ordinal Regression)


Idée clé : l'âge est **une variable ordonnée**, pas juste une classe discrète.

- On ne veut pas traiter “25 ans” et “26 ans” comme totalement indépendants.
- La méthode **ordinal** encode chaque âge comme une série de **comparaisons binaires** (est-ce $\geq X$ ans ?) et prédit des probabilités pour chaque seuil.

Méthode Ordinal - Resultats





```
test mae (cls, global): 4.464
=> MAE by age group (classification):
  0-17 yrs: mae=3.662, n=311, std(err)=5.335
  18-45 yrs: mae=3.787, n=1241, std(err)=3.147
  46-100 yrs: mae=7.023, n=426, std(err)=6.669
```




Best val mae : 3.804

Test mae : 4.464


Méthode Ordinal - Resultats





Résultats Globaux



- Diminution rapide de la loss au début de l'entraînement
- Convergence stable pour la plupart des modèles
- DEX, Residual et Ordinal atteignent les valeurs les plus basses
- DEX légèrement au-dessus mais proche des meilleurs
- Gaussian reste nettement plus élevé et moins performant
- Plateau global atteint après ~30–40 epochs



Zoom entre epoch
15 et 60



- Baisse rapide du MAE au début de l'entraînement
- Convergence autour de 4.5–4.6 pour la plupart des modèles
- Performances finales très proches (DEX, Laplace, Residual, Ordinal)
- Gaussian légèrement moins performant malgré un rattrapage
- Plateau atteint vers 30 epochs, avec peu d'amélioration ensuite

LabelSmoothing

Problème


DEX, utilise one-hot encoding ex: 20, 21, 22, 23, 24) $\rightarrow$ [0, 0, 1, 0, 0]. Favorise le sur-apprentissage, et le manque de généralisation

Le **Label Smoothing** introduit une incertitude et lisse les étiquettes cibles selon la formule :
 $y_{ls} = (1 - \alpha) \cdot y_{hot} + K\alpha$


- **Principe** : On abaisse la valeur de la bonne classe de $1 - \alpha$ et on distribue le % restants **uniformément** sur les K classes. Avec notre exemple $\rightarrow$ [0.02, 0.02, 0.92, 0.02, 0.02]
- **Utilité** : force le modèle à être moins sûr, le rend plus tolérant à l'erreur humaine

LabelSmoothing


- Sur-apprentissage
- 0.05 trop fort pour nos modèles



Pour plus de visibilité...



Label Smoothing 0.05



Label Smoothing 0.1

Backbone Performance Analysis

Backbone = réseau principal (feature extractor) d'un modèle CNN

- Extrait les caractéristiques importantes de l'image (formes, textures, traits du visage)
- Ces features sont ensuite utilisées par des couches supplémentaires pour prédire l'âge (DEX, régression, etc.)

Backbones comparés :



SEResNet50, ResNet101, SEResNeXt50_32x4d, EfficientNet-B0, EfficientNet-B3

Observations :


- EfficientNet-B0 est le plus rapide (~30 min vs ~2h), mais significativement moins précis
- EfficientNet-B3 est plus lent, mais atteint une précision comparable à SEResNet50
- Les autres modèles montrent des signes d'overfitting, particulièrement EfficientNet-B0

Résultat pour le modèle avec perte laplacienne

Les modèles convergent rapidement et présentent des performances proches. **EfficientNet-B3** obtient légèrement les meilleurs résultats sur la loss et le MAE.




Zoom (epochs 10–60)




- **EfficientNet-B3** est le modèle le plus performant et se généralise bien, mais son **coût de calcul élevé** impose un **batch size plus petit**.

Aperçu rapide


seresnet50-laplace




MAE over epochs




resnet101-laplace




MAE over epochs



efficientnet_b0-laplace





MAE over epochs





Distribution de l'âge et Incertitude

- La distribution est **fortement concentrée entre 20 et 40 ans**, avec un **pic autour de 25 ans**
- Le nombre d'exemples diminue progressivement après **40 ans**.
- Les âges supérieurs à **60 ans** sont **très peu représentés**.
- Les âges extrêmes (**0–10 ans** et **80–100 ans**) contiennent **très peu d'exemples**.



Distribution de l'âge et Incertitude



Ce déséquilibre peut expliquer pourquoi le modèle obtient de **moins bonnes performances sur les âges rares**. En effet, les modèles d'apprentissage profond sont sensibles à la distribution des données : les classes majoritaires influencent davantage la fonction de perte pendant l'entraînement. Le modèle tend donc à **optimiser ses prédictions pour les classes les plus fréquentes**, au détriment des classes rares.

Une distribution déséquilibrée

Observation

- Le **MAE est plus élevé pour les âges peu représentés** dans le dataset (par exemple les ages supérieurs à 50 ans).
- À l'inverse, il est **plus faible pour les tranches d'âge les plus fréquentes**.

```
N = counts.sum()
K = len(counts)

weights = N / (K * counts + 1e-6)
```

Solutions possibles

- **Weighted Loss** → agit sur la loss / gradient
- **Balanced Sampler** → agit sur la composition des batches
- **Enrichir le dataset** avec davantage d'exemples pour les âges **46–100**.

Résultats

On voit que ça rééquilibre un peu les erreurs entre les groupes, erreur sur les ages de plus de 50 a diminué et le modèle est plus stable sur ces tranches d'age mais ça dégrade légèrement la performance globale.

Baseline

```
test mae: 4.762
test acc: 0.096
=> MAE by age group:
  0-17 yrs: mae=4.091, n=311, std(err)=5.800
  18-45 yrs: mae=3.817, n=1241, std(err)=3.219
  46-100 yrs: mae=8.004, n=426, std(err)=7.070
```


Weighted Loss

```
test mae: 4.918
test acc: 0.060
=> MAE by age group:
  0-17 yrs: mae=3.172, n=311, std(err)=4.857
  18-45 yrs: mae=4.970, n=1241, std(err)=4.222
  46-100 yrs: mae=6.045, n=426, std(err)=6.027
```

balanced_sampler

```
test mae: 4.811
test acc: 0.190
=> MAE by age group:
  0-17 yrs: mae=3.703, n=311, std(err)=6.189
  18-45 yrs: mae=4.331, n=1241, std(err)=3.979
  46-100 yrs: mae=7.018, n=426, std(err)=6.278
```

Distribution des âges avec l'ajout d'images synthétiques



test mae: 4.622

test acc: 0.088

=> MAE by age group:


0-17 yrs: mae=3.311, n=311, std(err)=4.316

18-45 yrs: mae=3.854, n=1241, std(err)=3.236


46-100 yrs: mae=7.816, n=426, std(err)=7.131

Images synthétiques: Résultats

Loss comparison




MAE comparison



UTKFace : nouveau jeu de donnée


- **UTKFace** est un dataset d'images de visages utilisé pour l'estimation de **l'âge**, du **genre** et de **l'ethnie**.
- Il contient **plus de 20 000 images** de visages.
- Les âges vont de **0 à 116 ans**.




```
test mae: 5.755
test acc: 0.221
=> MAE by age group:
    0-17 yrs: mae=3.568, n=704, std(err)=6.999
    18-45 yrs: mae=4.991, n=2078, std(err)=4.968
    46-100 yrs: mae=9.507, n=834, std(err)=9.711
```


Ajustement du Learning Rate

Loss comparison



MAE comparison



Test-Time-Augmentation (TTA)

- Appliquer plusieurs transformations d'une image à l'inférence
- Moyenner les prédictions pour plus de robustesse
- Permet aussi d'estimer l'incertitude
- Coût : temps d'inférence plus élevé

Deux approches :

- Aléatoire
- Déterministe

<https://www.nature.com/articles/s41598-020-61808-3>

```
test mae: 4.705
test acc: 0.106
=> MAE by age group:
  0-17 yrs: mae=3.456, n=311, std(err)=5.545
  18-45 yrs: mae=3.853, n=1241, std(err)=3.366
  46-100 yrs: mae=8.098, n=426, std(err)=6.524
```

TTA déterministe

```
test mae: 4.642
test acc: 0.108
=> MAE by age group:
  0-17 yrs: mae=3.369, n=311, std(err)=5.266
  18-45 yrs: mae=3.985, n=1241, std(err)=3.457
  46-100 yrs: mae=7.488, n=426, std(err)=7.106
```

TTA aléatoire

Dropout et MC-Dropout


Dropout (entraînement)

- Éteint aléatoirement certaines neurones (p) → régularisation.
- Empêche le surapprentissage.
- Pendant le test, tous les neurones sont actifs.


MC-Dropout (inférence)

- Active le dropout **aussi en test**.
- Plusieurs passes → distribution des prédictions.
- Moyenne = prédiction, écart-type = incertitude.


Gal, Y. & Ghahramani, Z. (2016). *Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning*. ICML 2016.



Avant Dropout



Après Dropout



Conclusion

Nous avons testé plusieurs méthodes (TTA, résiduel, GAN-style, dropout, learning rate, backbone comme ResNeXt-50 32x4d). Nous avons réussi à améliorer les performances, notamment grâce à l'ordinal regression et au TTA.

Cependant, le modèle reste moins précis sur les âges peu représentés à cause du déséquilibre du dataset. Le modèle atteint une MAE d'environ 4 ans, ce qui est cohérent avec la difficulté du problème, car l'âge est difficile à estimer précisément à partir d'une image.

